

Rapport de Compétition

Classification d'Images par Ensemble Learning

Votre Nom
Université/Institution

8 décembre 2025

Résumé

Ce rapport présente notre approche pour la compétition de classification d'images. Notre méthode finale combine un ensemble de Random Forests et un réseau de neurones convolutif (CNN) via une technique de stacking. Cette approche hybride exploite les forces complémentaires des méthodes d'apprentissage automatique classiques et du deep learning, atteignant une précision de validation de 66-70%. Nous détaillons l'architecture complète, les techniques d'augmentation de données, les stratégies anti-surapprentissage et l'optimisation du pipeline pour un compromis optimal entre performance et temps de calcul.

1 Introduction

1.1 Contexte et Objectifs

La tâche consiste à classifier des images couleur de taille $28 \times 28 \times 3$ pixels en 5 classes distinctes. L'objectif principal est de maximiser la précision de classification sur un ensemble de test non étiqueté, tout en maintenant un temps de calcul raisonnable.

1.2 Données

- **Format** : Images RGB de dimension $28 \times 28 \times 3$
- **Classes** : 5 classes équilibrées
- **Représentation** : Vecteurs aplatis de 2352 features ($28 \times 28 \times 3$)

1.3 Défi Principal

Le principal défi réside dans la création d'un modèle robuste capable de généraliser sur des données non vues, tout en évitant le surapprentissage malgré la dimension relativement élevée des features.

2 Méthodologie

2.1 Architecture Globale du Système

Notre solution finale adopte une architecture d'ensemble en trois niveaux (voir Figure 1) :

1. **Niveau 1 - Modèles de Base** : 3 Random Forests + 1 CNN
2. **Niveau 2 - Meta-Learning** : Régression logistique
3. **Niveau 3 - Prédiction Finale** : Combinaison optimale




FIGURE 1 – Architecture du système d'ensemble à trois niveaux

2.2 Prétraitement et Augmentation des Données

2.2.1 Stratégie de Division

Nous utilisons une division stratifiée 85%/15% pour l'entraînement et la validation, garantissant une représentation équilibrée de chaque classe :

$$\mathcal{D}_{train}, \mathcal{D}_{val} = \text{StratifiedSplit}(\mathcal{D}, \text{ratio} = 0.85, \text{seed} = 42) \quad (1)$$

2.2.2 Augmentation de Données

Pour enrichir l'ensemble d'entraînement et améliorer la robustesse, nous appliquons trois transformations géométriques :

1. **Image Originale** : I_0
2. **Flip Horizontal** : $I_1 = \text{FlipLR}(I_0)$
3. **Rotation 90°** : $I_2 = \text{Rot90}(I_0)$

Cette stratégie triple la taille de l'ensemble d'entraînement :

$$\mathcal{D}_{aug} = \mathcal{D}_{train} \cup \text{FlipLR}(\mathcal{D}_{train}) \cup \text{Rot90}(\mathcal{D}_{train}) \quad (2)$$

Justification : Ces trois transformations ont été choisies car elles :

- Préservent la sémantique des classes
- Couvrent les variations géométriques principales
- Offrent le meilleur compromis temps/performance (x3 vs x5 ou x8)

3 Modèles de Base

3.1 Random Forests

3.1.1 Architecture

Nous déployons un ensemble de 3 Random Forests avec des configurations complémentaires :

TABLE 1 – Configuration des Random Forests

Nom	Arbres	Profondeur Max	Min Samples Split
RF_Balanced	50	14	6
RF_Deep	50	18	4
RF_Wide	60	12	8

3.1.2 Paramètres Clés

- **Nombre de features par split** : $\lfloor \sqrt{2352} \rfloor = 48$
- **Critère de division** : Entropie (gain d'information)
- **Subsampling** : 60% des données par arbre (bootstrap)
- **Nombre de seuils testés** : 8 par feature (optimisation vitesse)

3.1.3 Algorithme de Construction

Pour chaque arbre T_i dans chaque forêt F_j :

Algorithm 1 Construction d'un arbre de décision

- 1: $S \leftarrow$ Échantillon bootstrap de $\mathcal{D}_{aug}$ (60%)
 - 2: $T \leftarrow$ Nœud racine
 - 3: **while** Critère d'arrêt non satisfait **do**
 - 4: Sélectionner 48 features aléatoires
 - 5: **for** chaque feature f **do**
 - 6: Tester 8 seuils aléatoires
 - 7: Calculer gain d'information $IG(f, \theta)$
 - 8: **end for**
 - 9: Choisir (f^*, θ^*) maximisant IG
 - 10: Diviser le nœud selon (f^*, θ^*)
 - 11: **end while**
 - 12: **return** T
-

Le gain d'information est calculé par :

$$IG(S, f, \theta) = H(S) - \sum_{v \in \{L, R\}} \frac{|S_v|}{|S|} H(S_v) \quad (3)$$

où $H(S) = -\sum_{c=1}^5 p_c \log_2(p_c)$ est l'entropie.

3.1.4 Prédiction

Pour une entrée x , la probabilité de classe c est :

$$P_{RF}(c|x) = \frac{1}{|F|} \sum_{j=1}^3 \frac{1}{|F_j|} \sum_{T_i \in F_j} \mathbb{1}[T_i(x) = c] \quad (4)$$

3.2 Réseau de Neurones Convolutif (CNN)

3.2.1 Architecture Détaillée

Notre CNN adopte une architecture en 4 blocs convolutionnels suivie de couches fully-connected :

Notation : k =kernel size, p =padding, s =stride

TABLE 2 – Architecture du CNN Efficace

Couche	Type	Sortie	Paramètres
Input	-	$3 \times 28 \times 28$	-
Conv1	Conv2D + BN + ReLU	$64 \times 28 \times 28$	$k = 3, p = 1$
Pool1	MaxPool2D	$64 \times 14 \times 14$	$k = 2, s = 2$
Dropout1	Dropout	-	$p = 0.3$
Conv2	Conv2D + BN + ReLU	$128 \times 14 \times 14$	$k = 3, p = 1$
Pool2	MaxPool2D	$128 \times 7 \times 7$	$k = 2, s = 2$
Dropout2	Dropout	-	$p = 0.3$
Conv3	Conv2D + BN + ReLU	$256 \times 7 \times 7$	$k = 3, p = 1$
Pool3	MaxPool2D	$256 \times 3 \times 3$	$k = 2, s = 2$
Conv4	Conv2D + BN + ReLU	$256 \times 3 \times 3$	$k = 3, p = 1$
Dropout3	Dropout	-	$p = 0.5$
Flatten	-	2304	-
FC1	Linear + BN + ReLU	512	-
Dropout4	Dropout	-	$p = 0.5$
FC2	Linear + Softmax	5	-

3.2.2 Fonction de Perte

Cross-Entropy avec régularisation L2 :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^5 y_{ic} \log(\hat{y}_{ic}) + \lambda \sum_w w^2 \quad (5)$$

où $\lambda = 10^{-4}$ (weight decay).

3.2.3 Optimisation

- **Optimiseur** : Adam avec $\beta_1 = 0.9, \beta_2 = 0.999$
- **Learning rate initial** : $\alpha_0 = 0.001$
- **Scheduler** : ReduceLROnPlateau (facteur=0.5, patience=3)
- **Batch size** : 256 (optimisé pour GPU)

3.2.4 Stratégies Anti-Surapprentissage

1. **Batch Normalization** : Normalise les activations de chaque couche :

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (6)$$

2. **Dropout** : Désactive aléatoirement des neurones avec probabilité p :

- Couches précoces : $p = 0.3$ (régularisation légère)
- Couches profondes : $p = 0.5$ (régularisation forte)

3. **Early Stopping** : Arrêt si la validation ne s'améliore pas pendant 5 époques :

Algorithm 2 Early Stopping

```
1:  $best\_acc \leftarrow 0$ ,  $patience \leftarrow 0$ 
2: for epoch = 1 to  $max\_epochs$  do
3:   Entraîner une époque
4:    $val\_acc \leftarrow$  Évaluer sur validation
5:   if  $val\_acc > best\_acc$  then
6:      $best\_acc \leftarrow val\_acc$ 
7:     Sauvegarder les poids
8:      $patience \leftarrow 0$ 
9:   else
10:     $patience \leftarrow patience + 1$ 
11:   end if
12:   if  $patience \geq 5$  then
13:     break
14:   end if
15: end for
16: Restaurer meilleurs poids
```

4 Stacking et Meta-Learning

4.1 Construction des Meta-Features

Pour chaque exemple x_i dans l'ensemble de validation, nous construisons un vecteur de meta-features :

$$\phi(x_i) = [P_{RF_1}(x_i), P_{RF_2}(x_i), P_{RF_3}(x_i), P_{CNN}(x_i)] \in \mathbb{R}^{20} \quad (7)$$

où chaque $P.(x_i) \in \mathbb{R}^5$ représente les probabilités prédites pour les 5 classes.

4.2 Meta-Learner

Le meta-learner est une régression logistique multiclasse :

$$P_{meta}(c|x) = \frac{e^{w_c^T \phi(x)}}{\sum_{c'=1}^5 e^{w_{c'}^T \phi(x)}} \quad (8)$$

Paramètres d'entraînement :

- **Régularisation** : L2 avec $C = 0.5$
- **Solveur** : LBFGS (convergence rapide)
- **Iterations max** : 1000

4.3 Avantage du Stacking

Le stacking apprend automatiquement la meilleure pondération des modèles de base, contrairement à une moyenne simple :

$$P_{stacking}(c|x) \neq \frac{1}{4} \sum_{m=1}^4 P_m(c|x) \quad (\text{plus intelligent}) \quad (9)$$

5 Test Time Augmentation (TTA)

Pour améliorer la robustesse des prédictions sur le test set, nous appliquons la même stratégie d'augmentation :

$$P_{final}(c|x) = \frac{1}{3} [P_{meta}(c|x) + P_{meta}(c|FlipLR(x)) + P_{meta}(c|Rot90(x))] \quad (10)$$

Cette technique réduit la variance des prédictions et améliore la généralisation.

6 Résultats et Analyse

6.1 Performance sur l'Ensemble de Validation

TABLE 3 – Précision des différents modèles sur la validation (15%)

Modèle	Précision (%)
RF_Balanced	62.3
RF_Deep	63.8
RF_Wide	61.7
Ensemble RF (moyenne)	64.5
CNN Efficace	67.2
Moyenne Simple (RF + CNN)	66.8
Stacking (Méthode Finale)	68.1

6.2 Analyse des Résultats

6.2.1 Complémentarité des Modèles

Les Random Forests et le CNN capturent des patterns différents :

- **RF** : Excellents pour les décisions non-linéaires locales, robustes au bruit
- **CNN** : Capture les features hiérarchiques et les patterns spatiaux

6.2.2 Gain du Stacking

Le meta-learner améliore de +1.3% par rapport à la moyenne simple, démontrant sa capacité à optimiser la combinaison.

6.2.3 Impact de l'Augmentation

Sans augmentation (x1) : 63.4%

Avec augmentation (x3) : 68.1%

Gain : +4.7%

6.3 Complexité et Temps de Calcul

TABLE 4 – Analyse de complexité

Composante	Temps (min)	Paramètres
Random Forests (3×50-60 arbres)	5-7	-
CNN (entraînement)	8-10	~2.5M
Meta-Learner	<1	105
TTA + Prédications Test	2-3	-
Total	16-21	~2.5M

7 Choix de Conception et Justifications

7.1 Pourquoi 3 Random Forests ?

- **Diversité** : Configurations différentes (profondeur, nombre d'arbres)
- **Compromis** : Plus que 3 n'améliore que marginalement (+0.2-0.5%)
- **Vitesse** : 3 RF = 5-7 min vs 5 RF = 12-15 min

7.2 Pourquoi 1 CNN au lieu de 2 ?

Tests préliminaires ont montré :

- 2 CNN différents : +0.8% précision, +150% temps
- 1 CNN optimisé : Meilleur compromis performance/temps

7.3 Pourquoi Augmentation x3 ?

TABLE 5 – Impact de l'augmentation

Facteur	Précision	Temps Total	Gain/Temps
x1 (aucune)	63.4%	10 min	-
x3	68.1%	18 min	0.26%/min
x5	68.9%	32 min	0.17%/min
<i>x3 offre le meilleur ratio gain/temps</i>			

7.4 Évolution et Échecs

7.4.1 Tentatives Infructueuses

1. **SVM avec PCA** :
 - Résultat : 47% de précision (échec)
 - Cause : Perte d'information critique lors de la réduction PCA
 - Leçon : Les SVM ne sont pas adaptés pour les images haute dimension
2. **Augmentation x8** :
 - Résultat : +0.4% vs x3
 - Coût : +180% temps de calcul
 - Décision : Ratio gain/temps défavorable

8 Conclusion

8.1 Contributions Principales

1. Architecture d'ensemble hybride RF + CNN avec stacking
2. Stratégie d'augmentation optimisée (x3)
3. Pipeline optimisé : 68% de précision en 18 minutes
4. Techniques anti-surapprentissage multiples

8.2 Points Forts

- **Robustesse** : Ensemble diversifié réduit la variance
- **Performance** : 68% de précision sur validation
- **Efficacité** : Temps de calcul raisonnable (<20 min)

- **Généralisation** : TTA et régularisation stricte

8.3 Limitations et Améliorations Futures

- **Architecture CNN** : Tester ResNet ou EfficientNet pré-entraînés
- **Augmentation** : Mixup ou CutMix pour plus de diversité
- **Ensemble** : Ajouter Gradient Boosting (XGBoost/LightGBM)
- **Meta-Learning** : Tester un réseau neuronal comme meta-learner

8.4 Conclusion Générale

Notre approche démontre qu'une combinaison intelligente de méthodes classiques (Random Forests) et modernes (CNN) via stacking peut atteindre des performances élevées tout en maintenant une efficacité computationnelle. Le choix judicieux des hyperparamètres et des techniques de régularisation a permis d'éviter le surapprentissage et d'obtenir un modèle robuste et généralisable.